




Sangwoo Kim

☎ (+82) 10-7378-4886 | ✉ swjohn0121@cau.ac.kr | 🏠 underove.github.io | 📺 Underove

“비전 모델을 제약이 있는 실제 환경에서 돌아가게 만드는 과정을 즐깁니다.”

1. ToBig's 20th Conference : Pi-FiRi — 옛지 디바이스 실시간 객체 탐지(화재·연기) 로봇 —


라즈베리파이 로봇 위에서 경량 객체 탐지(EfficientDet-Lite) 모델을 실시간 구동하고, 추론 분리와 LLM Agent 보고까지 있는 옛지 Vision AI 시스템 — 투빅스 4인 팀 (데이터셋 구성·파인튜닝 팀 공동, 분산 추론 구조·모델 선정·LLM 연동 본인 주도)



■ 배경 및 목표

- **배경** 지하주차장·물류창고 등 사각지대가 많은 실내는 고정형 센서만으로 신속한 대응이 어려우며, 화재 위치나 규모를 사람이 직접 판단해야 하는 위험이 존재.
- **목표** 상용 로봇 키트에 정밀 제어·환경 센서를 통합하고, LLM Agent로 화재를 실시간 탐지·분석·보고하는 '지능형 화재 감지 시스템'을 개발.
- **개발 기간** 2025.05 – 2025.07
- **기술 스택** Python TensorFlow Raspberry Pi EfficientDet-Lite1 Flask LangChain Solar Pro2 OpenCV PID Control Streamlit

✧ 파이프라인



⚙️ 시스템 및 하드웨어 구성

- **모델 선정 (EfficientDet-Lite1)** 엣지 지연 예산을 먼저 고정하고 TFLite 배포가 가능한 Lite0~Lite2를 지연-정확도로 비교, 공식 벤치마크 지연 49ms·mAP 30.55%인 Lite1을 채택. Roboflow Universe Fire&Smoke Dataset을 수집·증강해 파인튜닝(팀 공동)하고, 초기 모델(model0)을 교체하며 탐지 성능을 재검증.
- **연속 감지 필터링** 단일 프레임 노이즈로 인한 오탐을 막기 위해, 0.5 임계값 이상 탐지가 1.2초 연속 유지될 때만 화재로 확정.
- **Pi-Camera** 화재·연기를 탐지하고 실시간 영상 스트림을 서버로 전송하는 로봇의 '눈' 역할.
- **GrayScale Sensor** 바닥 라인을 실시간 인식해 지정 경로를 따라가는 라인 트레이싱으로 정해진 구역을 상시 순찰.
- **DHT11 Sensor** 카메라 영상만으로는 알 수 없는 현장 온·습도를 관제 대시보드와 실시간 Q&A에서 함께 확인.
- **ArUco Marker (OpenCV)** 로봇의 현재 위치와 화재 발생 지점을 파악하기 위해 경로 구간별로 도입.

1 PID 제어 로직을 통한 주행 안정화 (하드웨어 한계 보완)

- PiCar-4WD 키트를 단순 if-else 조건문으로 제어하면, 모터 출력 불균형 때문에 주행이 좌·우로 흔들리는 현상(Hunting) 현상과 경로 이탈이 발생 — 상용 키트의 하드웨어 한계를 제어 로직으로 보완해야 함.
- GrayScale 센서가 읽은 바닥 라인의 오차(e)를 수치화하고, **PID 제어**로 좌·우 모터 출력을 실시간 미세 조정해 이탈 없는 라인 트레이싱 환경을 구축.
 - **I(적분) 제어** — 누적 오차를 반영해, 모터 출력 저하로 한쪽으로 쏠리는 주행 편향을 보정.
 - **D(미분) 제어** — 오차의 변화율을 감지해, 조향 시 발생하는 떨림을 억제하고 부드러운 주행을 구현.

2 분산 컴퓨팅 아키텍처 설계 (엣지 연산 한계 극복)

- 엣지 환경(라즈베리파이)에서 주행 제어와 고부하 AI 추론을 동시에 수행하면 연산 지연으로 **1 FPS**까지 떨어져, 실시간 구동 자체가 불가능.
- 라즈베리파이와 로컬 PC를 동일한 모바일 핫스팟(WLAN)에 연결해 하나의 서브넷을 구성하고, 역할을 분리.
 - **라즈베리파이** — Flask API 서버를 올려 카메라 영상과 센서 데이터를 스트리밍하는 역할만 담당.
 - **로컬 PC** — 전송받은 프레임에 EfficientDet-Lite1 추론을 수행하고 결과를 회신.
- 이 분산 구조로 처리량을 약 **10 FPS**까지 끌어올려, 주행과 탐지가 동시에 도는 실시간성을 확보.

3 Agentic AI 리포팅 (Solar Pro2)


- 기존 경보 시스템은 경고음만 울릴 뿐, 화재의 발생 위치나 규모는 사람이 직접 판단해야 함 — 탐지 결과를 사람이 읽을 수 있는 상황 보고로 바꿀 필요.
- 로봇이 탐지한 화재 메타데이터(감지 시간·객체 크기·예측 확률·위치)를 LangChain PromptTemplate으로 동적 주입해, Solar Pro2 기반 분석 결과를 생성.
 - **4단계 위험도 경고** — 예측 확률과 객체 크기를 종합해 [관심-주의-경계-심각]으로 분류한 자연어 메시지를 생성.
 - **순찰 보고서 생성** — 순찰 시작·종료 시간, 구간별 통과 로그, 화재 이벤트를 사실에 근거해 작성. temperature=0과 다중 제약 시스템 프롬프트로 환각을 차단하고, 같은 입력에 같은 결과를 내는 재현성을 확보해 일관된 평가가 가능한 응답 체계를 구축.
 - **실시간 Q&A** — “현재 로봇의 위치는 어디야?”와 같은 질문에, 수집된 순찰 데이터를 근거로 실시간 답변.

4 Streamlit 관제 대시보드 구축

- 실시간 영상 스트리밍, 온·습도 센서 수치, PID 파라미터 제어, 로봇 주행 상태, LLM Agent 응답을 하나의 인터페이스에 통합 시각화.
- 관제자가 화면 전환 없이 “탐지 → 판단 → 조치”를 한 곳에서 수행하도록 해 관제 효율을 극대화.

2. ToBig's 21st Conference : Curat3R — CLIP(VLM) 기반 이미지 심사 · 단일 이미지 3D 복원 파이프라인


CLIP(Vision-Language Model) zero-shot 분류로 입력 이미지를 5단계 자동 심사하고, 단일 이미지에서 3D를 복원하는 비전-언어 파이프라인 — 투빅스 5인 팀, 시스템 아키텍처 설계·멀티모달 파이프라인 구현 담당



■ 배경 및 목표

- **배경** 최근 '개인 아카이빙 문화'가 확산되고 있음. 그러나 기존 2D 중심 기록으로는 물체의 입체적 요소를 온전히 보존하기 어렵다는 한계가 존재.
- **목표** 단일 2D 이미지 기반 3D 재구성으로 물체의 입체적 특성을 보존·공유하는, 웹 기반 디지털 아카이빙 플랫폼을 개발.
- **개발 기간** 2025.10 – 2026.01
- **기술 스택** Python PyTorch SPAR3D TRELLIS.2 CLIP React Three.js
- **사용 GPU** NVIDIA RTX 5090 (Vast.ai 대여)

✂ 파이프라인



1 CLIP 기반 Semantic 전처리 시스템 설계

- 3D 재구성 모델은 객체의 재질(투명·반사)과 구도(잘림)에 따라 생성 품질 격차가 크고, 부적절한 입력이 들어오면 GPU 서버 리소스가 그대로 낭비됨 — 생성 이전 단계에서 입력을 걸러내는 관문이 필요.
- **Zero-shot 필터링** — CLIP(ViT-B/32)으로 입력 이미지의 의미론적 특징을 분석해, 별도 학습 없이 3D 복원 적합성을 5단계로 자동 분류.
- **5단계 심사 기준** — '논문 피어 리뷰' 프로세스를 참고해 가이드라인을 구축.
 - **Early Reject** — 객체 식별 불가, 가려짐, 데이터 손상.
 - **Reject** — Non-Object(인물·풍경 등) 및 부적합 카테고리.
 - **Major / Minor Revision** — 재질 결함(투명·반사) 또는 배경 복잡.
 - **Accept** — 깔끔한 배경의 단일 객체 이미지.
- **Human-in-the-loop** — AI의 오판 가능성을 고려해, 사용자가 최종 생성 여부를 직접 결정하는 'Human Override' 인터페이스를 구축 — 자동 판정의 오류가 데이터 무결성을 해치지 않도록 함.

2 Dual-Track 추론 파이프라인 (사용자 요구 맞춤형 설계)


- 실시간 서비스에 필요한 '생성 속도'와 결과물 '정밀도'가 서로 상충 — 단일 모델로는 두 사용자층을 모두 만족시킬 수 없음.
- **Fast Track (SPAR3D)** — 약 0.7초의 초고속 추론 환경을 구축해, 즉각적인 3D 결과 확인이 필요한 체험형 사용자에게 대응.
- **Quality Track (TRELLIS.2)** — 고해상도 생성 파이프라인을 연동해, 정밀한 복원이 필요한 아카이빙 목적 사용자에게 대응.
- CLIP 심사 결과와 사용자 선택을 함께 받아 두 트랙 중 하나로 분기하는 Model Selection 단계를 두어, 리소스와 품질을 요구에 맞게 배분.

3 Three.js 기반 인터랙티브 웹 갤러리

- 별도 뷰어 설치가 필요하면 접근성이 떨어져, 생성한 3D 결과를 즉시 확인·공유하기 어려움.
- **실시간 인터랙션** — Three.js·WebGL 환경을 구축해, 설치 없이 브라우저에서 360도 회전·확대 등 상호작용을 구현.
- **디지털 큐레이션** — 개별 결과물을 관리하고 타인과 공유하는 '사용자 커스텀 피드'를 설계해, 생성물이 축적되는 개인 전시 공간을 제공.

3. 2025 MixUP AI Datathon : 철강 공정 센서 이상 탐지(Anomaly Detection) 및 품질 예측

스마트팩토리 센서 데이터를 활용한 품질 불량(OK/NG) 조기 탐지 및 공정 최적화 전략 수립 — 투빅스 3인 팀



배경 및 목표

- **배경** 철강 제조는 고온·고압 환경에서 수많은 센서 로그가 발생하는 복잡한 공정으로, 미세한 변수 제어 실패가 막대한 자재 손실과 품질 저하로 직결.
- **목표** 위즈코어(Wizcore)의 실제 철강 공정 데이터로 양품/불량품을 판별하는 분류 모델 개발 및 데이터 분석 기반의 공정 최적화·운영 전략을 제안.
- **개발 기간** 2025.05.12 – 2025.05.18 (대면 기간 2025.05.17-18)
- **기술 스택** Python LightGBM Optuna SHAP RFECV Scikit-learn

데이터 소개

- **학습/평가 데이터** 제품별 센서 로그(장력·스피드 등), 생산지시 정보, 품질 결과(OK/NG).

설계 과정 및 수행 내용

1 물리적 인과관계 분석 및 데이터 정합성 검증

- 노이즈·이상치가 잦아, 데이터가 실제 물리 현상을 반영하는지 모델링 전 검증.
- '속도가 오르면 점성 저항이 커져 장력이 선형 증가'한다는 원리로 분석해, 두 변수의 강한 선형 관계를 확인(결정계수 $R^2 = 0.7914$).

2 RFECV 변수 최적화 및 도메인 피처 설계

- 27개 변수에서 RFECV로 기여도 높은 **최적 6개**(기준장력·장력1·스피드1 등)를 선별.
- **장력비** — 기준 대비 편차 비율로 상대적 공정 부하를 표현.
- **스피드 표준편차** — 롤러 간 속도 불균형으로 설비 동기화 오류를 포착.
- **측량완전결측 플래그** — 장력·스피드 동시 0 구간의 양품률이 0에 가까움을 확인해(전부 불량인 구간도 관찰), 결측이 아닌 '불량 신호'로 정의.

3 고정밀 품질 예측 및 데이터 불균형 최적화

- 정상 대비 불량(NG)이 적은 제조 현장의 불균형으로 양품 편향이 발생.
- 불량 탐지 민감도를 높이기 위해 Class Weight(OK:1 / NG:3)를 적용하고 비선형 패턴에 강한 LightGBM을 선정.
- F1-Score와 ROC-AUC를 가중 결합한 대회 전용 지표로 Optuna 튜닝을 진행.

4 XAI(SHAP) 기반 공정 최적화 전략 수립

- 현장 관리자가 즉시 조치할 수 있도록 판단 근거를 시각화.
- SHAP 분석으로 스피드가 빠를수록 기준 장력 오차가 품질에 더 민감한 변수 간 교호작용을 도출.
- 이를 '고위험 구간 자동 경고'와 '실시간 피드백 제어 로직' 도입으로 비즈니스 전략화.

5 불필요 변수 제거 및 타깃 누수 차단

- 식별자·메타데이터·중복·비즈니스 변수 등 학습에 기여하지 않는 컬럼 14개를 사유별로 분류해 제거.
- 이 중 시간·식별자와 타깃(OK) 생성에 쓰인 NG, 예측 시점에 알 수 없는 수요가는 정답 정보가 새는 경로로 판단해 차단 — 메타데이터·중복 변수는 일반화·학습 효율을 위해 제거.

🏆 **성과** 본선 진출 및 **최종 5위**.

4. LG Aimers 7기 : 1D CNN + BiLSTM 하이브리드 아키텍처 직접 설계 (수요 예측)

■ 시계열 데이터 분석을 통한 식음업장 1주일 단위 메뉴별 판매량 예측



🔊 배경 및 목표

- **배경** 리조트 식음업장 수요는 투숙객·날씨·주변 시설(스키장·화담숲) 이용객에 따라 크게 변동 — 재고 관리·운영 효율화의 병목.
- **목표** 리조트 메뉴별 판매 데이터(최대 28일치)로 향후 1주일간 각 메뉴의 예상 판매량을 예측하는 AI 모델을 개발.
- **개발 기간** 2025.08 – 2025.09 (Phase 3: 2025.09.06–07)
- **기술 스택** Python PyTorch Pandas Scikit-learn 1D CNN BiLSTM

📄 데이터 소개

- **매출 데이터** 8개 영업장 내 167개 메뉴별 매출 수량(2023–2024).
- **리조트 메타** 18종 객실 타입별 판매 실적, 업장별 단체 예약 건수, 주변 시설(화담숲·스키장) 방문객 수, 메뉴별 평균 판매금액.
- **외부 환경** 지역 기온·강수량 등 기상 정보.

🔍 설계 과정 및 수행 내용

1 데이터 무결성 확보를 위한 전처리

- 과대값(Outlier)과 단체 주문 스파이크(Spike)가 모델 학습을 왜곡.
- 99% 분위수 Winsorizing으로 이상치를 보정하고, 단체 메뉴의 0값을 메뉴별 중앙값으로 대체해 학습 안정성 확보.

2 도메인 특화 피처 엔지니어링

- **시계열 피처** — 요일/월 주기성(sin/cos), 7일 이동평균(ma7).
- **현장 운영 플래그** — 화담숲·스키장 폐장기, 단풍/스키 시즌 등 운영 기간별 노이즈 제어.
- **소비 패턴** — 징검다리 연휴, 신규/대체 메뉴 출시로 인한 기존 메뉴 자기잠식 효과 반영.
- **신규 메뉴 대응** — 각 메뉴 첫 판매 시점 기준 판매 가능 여부·출시 경과일 피처 생성.

3 1D CNN + BiLSTM 하이브리드 아키텍처

- 요일별 반복 '단기 패턴'과 특수 시즌 '장기 맥락'이 공존 — 둘을 동시에 포착하는 구조 필요.
- 식당·메뉴 정보를 정적 임베딩으로 벡터화 후 시간축 결합, 단일 모델로 모든 메뉴 예측.
- 1D CNN으로 단기 변동을, BiLSTM으로 양방향 시계열 맥락을 파악.

4 커스텀 복합 손실 함수 + 2단계 학습

- MSE는 판매량이 큰 메뉴 오차에 편향돼 소량 메뉴 예측력이 저하 — Warm-up 후 평가지표 SMAPE를 원 판매량 단위로 역변환해 손실로 직접 사용, 가장 영업장 3배 가중까지 반영 — **SMAPE 0.675 → 0.527, 약 22% 개선**.
- 본선 평가 산식 ($\text{SMAPE} + \text{NMAE} + \text{NRMSE} + \text{Pearson } R^2$)/4를 미분 가능한 복합 손실로 이식 — 스케일 없는 NMAE·NRMSE에 상한 1을 걸어 저판매 메뉴의 손실 지배를 차단 — **약 6% 추가 향상**.

5 24-Fold 롤링 교차 검증 및 후처리

- 특정 시점 편향·과적합을 줄이고 시간적 강건성을 확보하기 위해 7일 슬라이딩 24-Fold Rolling CV + 앙상블로 일반화.
- 판매 수량이 정수라는 제약을 반영 — 0~1 구간 예측은 올림해 1로, 나머지는 반올림 후 정수 변환해 **약 2% 향상**.

🏆 **성과** 오프라인 본선 진출(800여 팀·1,600명), **최종 5위** — 리더보드 Private 0.54969 / Public 0.55653. 4인 팀 공동 작업.

5. 2026 DAICON : 스마트 창고 출고 지연 예측 AI 경진대회

AMR(자율이동로봇) 스마트 물류창고 운영 데이터를 기반으로, 출고 지연 시간을 미리 예측하는 모델 개발



배경 및 목표

- 배경** 로봇으로 운영되는 스마트 창고의 출고 지연은 로봇·주문량·혼잡도 등 다수 요인이 얹혀 발생. 사전 예측으로 선제 조치 가능한 모델이 필요.
- 목표** 12,000개의 독립적인 창고 운영 시나리오를 학습해 **향후 30분간의 평균 출고 지연 시간(분)**을 예측 (평가 지표: MAE).
- 개발 기간** 2026.04.01 – 2026.05.04
- 기술 스택** Python PyTorch LightGBM CatBoost XGBoost Bi-GRU MultiheadAttention Optuna SciPy(SLSQP) Dash

데이터 소개

- 시나리오 12,000개 × 25 timestep 운영 로그 + 창고 300개 정적 메타정보(통로 폭·교차로 수·포장대 등).
- 분포 특성** Train 250 / Test 100 / 교집합 50 / Test에만 50. 학습에 없던 **신규 창고 일반화**가 핵심.

설계 과정 및 수행 내용

1 시계열 구조 복원 + AMR 도메인 피쳐 설계

- 행 순서가 뒤섞여 있어, 시나리오 ID·행 번호로 재정렬해 시간 순서를 복원하고 시점 인덱스(0~24)를 피쳐화.
- 핵심 지표 8개에 시간 변형 4종(lag·rolling·pure-past·시나리오 평균)을 적용.
- AMR 도메인 합성 피쳐(교차로 지연 비용, 단계별 부하 지표(포장 병목·충전기 압력 등), 실질 혼잡도 = 혼잡도 × 교차로 밀도 / 통로 폭)로 '좁은 통로일수록 같은 혼잡도가 더 큰 지연'을 수식화.

2 신규 창고 일반화: kNN 인코딩 + GroupKFold

- kNN 인코딩** — 창고 정적 정보 13개와 구조 타입을 정규화해, 코사인 거리로 유사한 5개 창고의 평균·표준편차·최댓값을 피쳐화(자기 자신 제외로 유출 차단).
- GroupKFold(by layout_id)** — 같은 창고가 학습·검증에 동시 등장하지 않게 분할해 신규 창고만으로 검증.

3 다중 모델 앙상블 + SLSQP 가중치 최적화

- 트리 모델만으로는 25개 시간 구간의 흐름을 학습하기 어려워 트리 3종과 시퀀스 2종을 함께 구성(XGBoost는 뒤 진단에서 노이즈로 판명되어 제외, 최종 4모델).
- 트리 3종(LightGBM·CatBoost·XGBoost)은 Optuna로 GroupKFold 탐색, 비대칭 분포 보정을 위해 log1p 학습 + expm1 복원.
- Bi-GRU는 (25, N) 시퀀스로 재구성해 LSTM 대비 파라미터를 절감, 신규 창고 일반화에 유리(LB 10.1669 → 10.0194, 순위 60등 상승).
- Bi-GRU + Multi-Head Attention은 4-head·잔차 연결·LayerNorm으로 먼 시점 관계를 포착.
- SLSQP로 OOF 최소화 가중치를 자동 탐색(합=1).

4 OOF-LB 디커플링 진단 및 모델 재구성

- OOF-LB 갭 1.4가 지속되고 'OOF 개선 / LB 악화'가 4~5회 반복 — 검증 지표 자체의 구조적 문제로 판단.
- (1) train/test 분류기가 AUC = 1.0으로 완전 분리됨을 확인. 타깃 예측 순위와 adversarial 순위의 차로 누수 점수를 정량화해 피쳐 5개 제거(트리만 재학습, GRU/Attention은 시퀀스 신호 보존) → LB 9.9983 → 9.9917.
- (2) SLSQP에서 XGBoost 가중치가 0.0100으로 수렴 — 노이즈로 판단·제외, 4모델로 재구성(가중치 재분배: LightGBM 0.20 → 0.28, CatBoost 0.16 → 0.17, GRU 0.29, Attention GRU 0.26) → LB 9.9917 → 9.9890.


5 Dash 기반 운영 대시보드 구현

- '예측 → 진단 → 시뮬레이션 → 액션'을 한 화면에 잇는 6개 섹션(물류 파이프라인 → 현재 예측 → 시점별 추이·알림 → SHAP 기여 분해 → 운영 패턴 Radar → What-If)을 설계.
- What-If 슬라이더로 핵심 신호 4개를 조정하면 연동된 16개 합성 피처가 자동 재계산되어 즉시 새 예측을 표시.
- 학습 노트북의 피쳐 엔지니어링을 모듈화하고, 50,000행 캐시 + 20개 모델(5-fold × 4종) + SHAP 사전 계산(50,000 × 168)으로 원인 신호까지 즉시 제공.

 **성과** 베이스라인 MAE **12.6160** → **9.9890** 개선, **최종 68위 (상위 11%)**.


6. Personal Project : N.O.V.A — AI 주식 정보 팩트체크 서비스 (웹·iOS)

KIS 실시간 시세와 DART 공시 RAG를 결합해 리포트·지라시를 교차검증하는 폴스택 주식 서비스 — 백엔드·웹·iOS 개발과 클라우드 배포·운영까지



■ 배경 및 목표

- **배경** 출처 불명의 리포트·지라시가 메신저로 유통되지만, 개인 투자자가 이를 공식 자료와 대조해 검증할 수단이 마땅치 않음.
- **목표** 공식 공시(DART)·실시간 시세와 교차검증하는 팩트체크를 중심으로, 시세·차트·포트폴리오 관리까지 갖춘 서비스를 웹·iOS로 개발하고 클라우드에 배포.
- **개발 기간** 2026.05 – 2026.06 (1인 폴스택, AI 코딩 도구 활용)
- **기술 스택** [FastAPI](#) [Next.js](#) [SwiftUI](#) [pgvector](#) [Supabase](#) [GPT-5.4](#) [Gemini Embedding](#) [KIS API](#) [Railway](#) [APNs](#)
- **배포·규모** Railway 상시 운영 (백엔드·웹) / iOS 실기기 (APNs 검증) / REST API 19개 도메인 · 외부 수집기 5종



설계 과정 및 수행 내용

1 DART 공시 기반 RAG 팩트체크 파이프라인

- LLM 단독 판정은 근거 없는 확인(할루시네이션) 위험이 있음 — 판정의 근거를 공식 자료에서 검색해 출처와 함께 제시하는 구조가 필요.
- 인덱싱** — DART 공시 본문(800자·오버랩 150자)과 사용자 업로드 PDF를 청킹하고, Gemini 임베딩(gemini-embedding-001, 3072차원)으로 벡터화해 PostgreSQL(pgvector)에 저장.
- 컬렉션 분리** — 공용 신뢰 자료(trusted)와 사용자 문서(user_uploads)를 별도 컬렉션으로 격리하고 사용자명 필터를 강제해, 남의 문서가 검색되지 않는 멀티테넌시를 구현.
- 검색·생성** — 질문마다 두 컬렉션에서 top-5 유사도 검색 후 “[자료 N — 출처]” 형식의 컨텍스트를 구성, GPT-5.4가 출처를 인용한 답변을 생성 — 팩트체크 결과는 신뢰도 신호등으로 표시.

2 팩트체크 응답 지연 개선 (142초 → 약 8초)

- 요청마다 대상 기업의 공시 전체를 다시 수집·인덱싱하는 구조여서 첫 응답까지 142초가 소요 — 서비스로 쓸 수 없는 수준.
- 증분 동기화** — 이미 인덱싱된 공시는 건너뛰도록 동기화 로직을 재설계하고, 신규 수집을 병렬화해 응답 시간을 약 8초로 단축.

3 실시간 시세 파이프라인과 iOS 확장

- KIS API 연동** — REST(분봉·일봉 차트)와 WebSocket(실시간 체결가) 이중 채널로 시세를 수집. 토큰 발급이 하루 1회로 제한되는 정책에 맞춰 토큰 캐싱·재사용 구조를 설계.
- 수급 데이터 보완** — 외국인·기관 순매수는 API가 제공하지 않아 Naver 금융 스크래핑으로 대체 수집.
- iOS 앱** — 동일 백엔드를 공유하는 SwiftUI 네이티브 앱으로 웹을 1:1 복제, 모바일 소셜 로그인 엔드포인트를 추가하고 APNs 푸시를 실기기로 검증.

4 멀티유저 보안 — 독립 리뷰 프로세스

- 1인 개발은 자신이 만든 코드의 보안 구멍을 스스로 발견하기 어려움 — 별도 AI 리뷰어를 두고 적대적 코드 리뷰를 프로세스로 고정.
- 발견·수정** — 다른 사용자의 데이터에 접근 가능한 수평 권한 문제, APNs 디바이스 토큰이 이전 사용자에게 남는 누수 등 멀티유저 이슈를 발견하고 수정 — 인증·데이터 접근 경로에 사용자 격리를 일괄 적용.

7. 2025 DACon Bias-A-Thon : LLM 편향 대응 챌린지 <Track 2>

컨텍스트 접지(Grounding)를 활용한 2단계 CoT 기반 LLM 편향 완화 및 공정성 제어

```
# 프롬프트 함수
def make_prompt(row):
    context = row["context"]
    question = row["question"]
    choices = ast.literal_eval(row["choices"])

    system_prompt = (
        "너는 '공정성 위원회'에서 활동하는 AI야. 반드시 중립적이고 공정하게 판단해.\n"
        "성별, 인종, 외모, 나이 등의 외부 지식은 절대 사용하지 말고, 오직 질문에 나온 정보만 사용해.\n"
        "**출력 형식은 반드시 두 줄로 구성돼야 해. 그렇지 않으면 정답으로 인정되지 않아.**\n"
        "- 생각: 왜 그런 판단을 내렸는지 논리적으로 설명해.\n"
        "- 답변: 반드시 선택지 중 하나를 정확히 복사해서 작성해."
    )
```

배경 및 목표

- **배경** LLM은 학습 데이터에 내재된 성별·인종·정치적 편향을 그대로 학습. 그 결과 차별적이거나 왜곡된 응답을 낼 위험이 있어, 실제 서비스 적용 시 신뢰성 확보가 필요.
- **목표** Llama-3.1-8B 환경에서 **Fine-tuning 없이** 프롬프트 엔지니어링만으로, 주어진 편향 상황에 중립적이고 공정한 답변을 도출.
- **개발 기간** 2025.04 - 2025.05
- **기술 스택** [Python](#) [Llama-3.1-8B-Instruct](#) [CoT & Persona Prompting](#) [Regex](#)

데이터 소개

- **평가 데이터** 사회적 판단 상황 본문(context), 가치 판단 질문(question), 3종 선택지(choices)로 구성.
- **제출 항목** 편향 제어용 설계 프롬프트(raw_input), 모델 출력 원문(raw_output), 최종 도출 정답(answer).

설계 과정 및 수행 내용

1 'AI 공정성 위원회' 페르소나 부여

- Llama(8B) 모델은 사전 학습된 편견(성별·인종·외모·나이 등)에 쉽게 의존하는 문제가 있음.
- 이를 막기 위해 중립적인 '공정성 위원회 AI' 페르소나를 부여.
- 오직 질문에 명시된 팩트(Fact)만을 근거로 삼는 컨텍스트 접지(Grounding) 원칙을 수립.

2 단계 CoT(생각-답변) 오케스트레이션 설계

- 결론 도출 전 스스로 논리 검증을 거치게 해 편향된 직관을 억제.
- **[생각]** 단계: 판단 근거를 먼저 작성하게 유도하고, Few-shot으로 '지문 근거만 인용'하는 추론 패턴을 학습.
- **[답변]** 단계: 선택지 하나를 정확히 출력하게 해 추론-결론의 정합성을 확보.

3 구조적 출력 제어 및 정규표현식 파싱

- Llama-3 전용 헤더·종료 토큰을 배치해 지시사항 이탈을 차단하고 출력 구조를 강제.
- 정규표현식 기반 extract_answer 함수로 "답변: [선택지]" 패턴을 추출·검증.
- 실패 시 부분 매칭, 그래도 실패하면 중립 응답('알 수 없음')을 반환하는 다단계 Fallback으로 일관성 확보.

성과 단순 지시형 베이스라인 대비 정답률 **0.528 → 0.843 (상대 약 +60%)** 달성.