




# Sangwoo Kim

☎ (+82) 10-7378-4886 | ✉ swjohn0121@gmail.com | 🏠 underove.github.io | 📺 Underove

“끊임없이 도전하고, 이론을 현실에서 작동하는 시스템으로 구현하는 과정을 즐깁니다.”


## 1. Personal Project : N.O.V.A — AI 주식 정보 팩트체크 서비스 (웹·iOS)

■ KIS 실시간 시세와 DART 공시 RAG를 결합해 리포트·지라시를 교차검증하는 폴스택 주식 서비스 — 백엔드·웹·iOS 개발과 클라우드 배포·운영까지



### ■ 배경 및 목표

- **배경** 출처 불명의 리포트·지라시가 메신저로 유통되지만, 개인 투자자가 이를 공식 자료와 대조해 검증할 수단이 마땅치 않음.
- **목표** 공식 공시(DART)·실시간 시세와 교차검증하는 팩트체크를 중심으로, 시세·차트·포트폴리오 관리까지 갖춘 서비스를 웹·iOS로 개발하고 클라우드에 배포.
- **개발 기간** 2026.05 – 2026.06 (1인 폴스택, AI 코딩 도구 활용)
- **기술 스택** FastAPI | Next.js | SwiftUI | pgvector | Supabase | GPT-5.4-mini-5.4 | Gemini Embedding | KIS API | Railway | APNs
- **배포·규모** Railway 상시 운영 (백엔드·웹) / iOS 실기기 (APNs 검증) / REST API 19개 도메인 · 외부 수집기 5종



## 설계 과정 및 수행 내용

### 1 DART 공시 기반 RAG 팩트체크 파이프라인

- LLM 단독 판정은 근거 없는 확신(할루시네이션) 위험이 있음 — 판정의 근거를 공식 자료에서 검색해 출처와 함께 제시하는 구조가 필요.
- **인덱싱** — DART 공시 본문(800자·오버랩 150자)과 사업보고서 주요 재무 계정(연결 재무제표 기준), 사용자 업로드 PDF를 청킹하고, Gemini 임베딩(gemini-embedding-001, 3072차원)으로 벡터화해 PostgreSQL(pgvector)에 저장.
- **컬렉션 분리** — 공용 신뢰 자료(trusted)와 사용자 문서(user\_uploads)를 별도 컬렉션으로 격리하고 사용자명 필터를 강제해, 남의 문서가 검색되지 않는 멀티테넌시를 구현.
- **검색·생성** — 질문마다 두 컬렉션에서 top-5 유사도 검색 후 “[자료 N — 출처]” 형식의 컨텍스트를 구성, GPT-5.4-mini가 출처를 인용한 답변을 생성 — 팩트체크 결과는 신뢰도 신호등으로 표시.

### 2 팩트체크 응답 지연 개선 (142초 → 약 8초)

- 요청마다 대상 기업의 공시 전체를 다시 수집·인덱싱하는 구조여서 첫 응답까지 142초가 소요 — 서비스로 쓸 수 없는 수준.
- **증분 동기화** — 이미 인덱싱된 공시는 건너뛰도록 동기화 로직을 재설계하고, 신규 수집을 병렬화해 응답 시간을 약 8초로 단축.

### 3 실시간 시세 파이프라인·LLM 에이전트와 iOS 확장


- **KIS API 연동** — REST(분봉·일봉 차트)와 WebSocket(실시간 체결가) 이중 채널로 시세를 수집. 토큰 발급이 하루 1회로 제한되는 정책에 맞춰 토큰 캐싱·재사용 구조를 설계.
- **LLM function calling** — 시세 조회·공시 검색·기술지표 계산을 도구로 등록해 모델이 질문에 따라 직접 호출·조합하는 에이전트 구조를 구현 — 문서 검색(RAG)만으로 답할 수 없는 실시간 질의를 처리.
- **수급 데이터 보완** — 외국인·기관 순매수는 API가 제공하지 않아 Naver 금융 스크래핑으로 대체 수집.
- **iOS 앱** — 동일 백엔드를 공유하는 SwiftUI 네이티브 앱으로 웹을 1:1 복제, 모바일 소셜 로그인 엔드포인트를 추가하고 APNs 푸시를 실기기로 검증.

### 4 멀티유저 보안 — 독립 리뷰 프로세스

- 1인 개발은 자신이 만든 코드의 보안 구멍을 스스로 발견하기 어려움 — 별도 AI 리뷰어를 두고 적대적 코드 리뷰를 프로세스로 고정.
- **발견·수정** — 다른 사용자의 데이터에 접근 가능한 수평 권한 문제, APNs 디바이스 토큰이 이전 사용자에게 남는 누수 등 멀티유저 이슈를 발견하고 수정 — 인증·데이터 접근 경로에 사용자 격리를 일괄 적용.

## 2. LG Aimers 7기 : 식음업장 메뉴 수요 예측 AI 모델

■ 시계열 데이터 분석을 통한 식음업장 1주일 단위 메뉴별 판매량 예측



### 🔊 배경 및 목표

- **배경** 리조트 식음업장 수요는 투숙객·날씨·주변 시설(스키장·화담숲) 이용객에 따라 크게 변동 — 재고 관리·운영 효율화의 병목.
- **목표** 리조트 메뉴별 판매 데이터(최대 28일치)로 향후 1주일간 각 메뉴의 예상 판매량을 예측하는 AI 모델을 개발.
- **개발 기간** 2025.08 – 2025.09 (Phase 3: 2025.09.06–07)
- **기술 스택** Python PyTorch Pandas Scikit-learn 1D CNN BiLSTM

### 📊 데이터 소개

- **매출 데이터** 8개 영업장 내 167개 메뉴별 매출 수량(2023–2024).
- **리조트 메타** 18종 객실 타입별 판매 실적, 업장별 단체 예약 건수, 주변 시설(화담숲·스키장) 방문객 수, 메뉴별 평균 판매금액.
- **외부 환경** 지역 기온·강수량 등 기상 정보.

### 🔍 설계 과정 및 수행 내용

#### 1 데이터 무결성 확보를 위한 전처리

- 과대값(Outlier)과 단체 주문 스파이크(Spike)가 모델 학습을 왜곡.
- 99% 분위수 Winsorizing으로 이상치를 보정하고, 단체 메뉴의 0값을 메뉴별 중앙값으로 대체해 학습 안정성 확보.

#### 2 도메인 특화 피처 엔지니어링 — 예선 40여 개 실험 → 본선 10개 정제화

- **외부 시계열 결합(본선)** — 화담숲 이용객·스키장 1일 내장객 등 외부 방문 지표를 날짜 기준으로 판매 시계열에 병합해, 리조트 수요를 움직이는 외생 변수를 표현.
- **연휴 구조 분해(본선)** — 연휴를 단일 플래그가 아닌 블록 내 위치·블록 길이로 분해해, 같은 연휴 안에서도 날짜별로 다른 수요 패턴을 포착.
- **피처 정제화** — 예선에서 검증다리 연휴·신규/대체 메뉴 자기잠식·시즌 운영 플래그 등 40여 개 피처를 실험하고, 본선에서 검증 성능 기준으로 요일 주기성·이동평균·연휴 블록·외부 방문 지표 중심의 **10개 핵심 피처**로 축소.

#### 3 1D CNN + BiLSTM 하이브리드 아키텍처

- 요일별 반복 '단기 패턴'과 특수 시즌 '장기 맥락'이 공존 — 둘을 동시에 포착하는 구조 필요.
- 식당·메뉴 정보를 정적 임베딩으로 벡터화 후 시간축 결합, 단일 모델로 모든 메뉴 예측.
- 1D CNN으로 단기 변동을, BiLSTM으로 양방향 시계열 맥락을 파악.

#### 4 커스텀 복합 손실 함수 + 2단계 학습

- MSE는 판매량이 큰 메뉴 오차에 편향돼 소량 메뉴 예측력이 저하 — Warm-up 후 평가지표 SMAPE를 원 판매량 단위로 역변환해 손실로 직접 사용, 가장 영업장 3배 가장까지 반영 — **SMAPE 0.675 → 0.527, 약 22% 개선**.
- 본선 평가 산식  $(\text{SMAPE} + \text{NMAE} + \text{NRMSE} + \text{Pearson } R^2) / 4$ 를 미분 가능한 복합 손실로 이식 — 스케일 없는 NMAE·NRMSE에 상한 1을 걸어 저판매 메뉴의 손실 지배를 차단 — **약 6% 추가 향상**.

#### 5 24-Fold 롤링 교차 검증 및 후처리

- 특정 시점 편향·과적합을 줄이고 시간적 강건성을 확보하기 위해 7일 슬라이딩 24-Fold Rolling CV + 앙상블로 일반화.
- 판매 수량이 정수라는 제약을 반영 — 0~1 구간 예측은 올림해 1로, 나머지는 반올림 후 정수 변환해 **약 2% 향상**.

🏆 **성과** 오프라인 본선 진출(800여 팀·1,600명), **최종 5위** — 리더보드 Private 0.54969 / Public 0.55653. 4인 팀 공동 작업.

### 3. 2026 DAICON : 스마트 창고 출고 지연 예측 AI 경진대회

AMR(자율이동로봇) 스마트 물류창고 운영 데이터를 기반으로, 출고 지연 시간을 미리 예측하는 모델 개발



#### 배경 및 목표

- 배경 로봇으로 운영되는 스마트 창고의 출고 지연은 로봇·주문량·혼잡도 등 다수 요인이 얽혀 발생. 사전 예측으로 선제 조치 가능한 모델이 필요.
- 목표 12,000개의 독립적인 창고 운영 시나리오를 학습해 **향후 30분간의 평균 출고 지연 시간(분)**을 예측 (평가 지표: MAE).
- 개발 기간 2026.04.01 – 2026.05.04
- 기술 스택 Python PyTorch LightGBM CatBoost XGBoost Bi-GRU MultiheadAttention Optuna SciPy(SLSQP) Dash

#### 데이터 소개

- 시나리오 12,000개 × 25 timestep 운영 로그 + 창고 300개 정적 메타정보(통로 폭·교차로 수·포장대 등).
- 분포 특성 Train 250 / Test 100 / 교집합 50 / Test에만 50. 학습에 없던 신규 창고 일반화가 핵심.

#### 설계 과정 및 수행 내용

##### 1 시계열 구조 복원 + AMR 도메인 피쳐 설계

- 행 순서가 뒤섞여 있어, 시나리오 ID·행 번호로 재정렬해 시간 순서를 복원하고 시점 인덱스(0-24)를 피쳐화.
- 핵심 지표 8개에 시간 변형 4종(lag·rolling·pure-past·시나리오 평균)을 적용.
- AMR 도메인 합성 피쳐(교차로 지연 비용, 단계별 부하 지표(포장 병목·충전기 압력 등), 실질 혼잡도 = 혼잡도 × 교차로 밀도 / 통로 폭)로 '좁은 통로일수록 같은 혼잡도가 더 큰 지연'을 수식화.

##### 2 신규 창고 일반화: kNN 인코딩 + GroupKfold

- kNN 인코딩 — 창고 정적 정보 13개와 구조 타입을 정규화해, 코사인 거리로 유사한 5개 창고의 평균·표준편차·최댓값을 피쳐화(자기 자신 제외로 유출 차단).
- GroupKfold(by layout\_id) — 같은 창고가 학습·검증에 동시 등장하지 않게 분할해 신규 창고만으로 검증.

### 3 다중 모델 앙상블 + SLSQP 가중치 최적화

- 트리 모델만으로는 25개 시간 구간의 흐름을 학습하기 어려워 트리 3종과 시퀀스 2종을 함께 구성(XGBoost는 뒤 진단에서 노이즈로 판명되어 제외, 최종 4모델).
- 트리 3종(LightGBM·CatBoost·XGBoost)은 Optuna로 GroupKFold 탐색, 비대칭 분포 보정을 위해 log1p 학습 + expm1 복원.
- Bi-GRU는 (25, N) 시퀀스로 재구성해 LSTM 대비 파라미터를 절감, 신규 창고 일반화에 유리(LB 10.1669 → 10.0194, 순위 60등 상승).
- Bi-GRU + Multi-Head Attention은 4-head·잔차 연결·LayerNorm으로 먼 시점 관계를 포착.
- SLSQP로 OOF 최소화 가중치를 자동 탐색(합=1).

### 4 OOF-LB 디커플링 진단 및 모델 재구성

- OOF-LB 갭 1.4가 지속되고 'OOF 개선 / LB 악화'가 4~5회 반복 — 검증 지표 자체의 구조적 문제로 판단.
- (1) train/test 분류기가 AUC = 1.0으로 완전 분리됨을 확인. 타깃 예측 순위와 adversarial 순위의 차로 누수 점수를 정량화해 피쳐 5개 제거(트리만 재학습, GRU/Attention은 시퀀스 신호 보존) → LB 9.9983 → 9.9917.
- (2) SLSQP에서 XGBoost 가중치가 0.0100으로 수렴 — 노이즈로 판단·제외, 4모델로 재구성(가중치 재분배: LightGBM 0.20 → 0.28, CatBoost 0.16 → 0.17, GRU 0.29, Attention GRU 0.26) → LB 9.9917 → 9.9890.

### 5 Dash 기반 운영 대시보드 구현

- '예측 → 진단 → 시뮬레이션 → 액션'을 한 화면에 잇는 6개 섹션(물류 파이프라인 → 현재 예측 → 시점별 추이·알림 → SHAP 기여 분해 → 운영 패턴 Radar → What-If)을 설계.
- What-If 슬라이더로 핵심 신호 4개를 조정하면 연동된 16개 합성 피쳐가 자동 재계산되어 즉시 새 예측을 표시.
- 학습 노트북의 피쳐 엔지니어링을 모듈화하고, 50,000행 캐시 + 20개 모델(5-fold × 4종) + SHAP 사전 계산(50,000 × 168)으로 원인 신호까지 즉시 제공.

 **성과** 베이스라인 MAE **12.6160** → **9.9890** 개선, **최종 68위 (상위 11%)**.

## 4. 2025 DACon Bias-A-Thon : LLM 편향 대응 챌린지 <Track 2>

컨텍스트 접지(Grounding)를 활용한 2단계 CoT 기반 LLM 편향 완화 및 공정성 제어

```
# 프롬프트 함수
def make_prompt(row):
    context = row["context"]
    question = row["question"]
    choices = ast.literal_eval(row["choices"])

    system_prompt = (
        "너는 '공정성 위원회'에서 활동하는 AI야. 반드시 중립적이고 공정하게 판단해.\n"
        "성별, 인종, 외모, 나이 등의 외부 지식은 절대 사용하지 말고, 오직 질문에 나온 정보만 사용해.\n"
        "**출력 형식은 반드시 두 줄로 구성돼야 해. 그렇지 않으면 정답으로 인정되지 않아.**\n"
        "- 생각: 왜 그런 판단을 내렸는지 논리적으로 설명해.\n"
        "- 답변: 반드시 선택지 중 하나를 정확히 복사해서 작성해."
    )
```

### 배경 및 목표

- 배경** LLM은 학습 데이터에 내재된 성별·인종·정치적 편향을 그대로 학습. 그 결과 차별적이거나 왜곡된 응답을 낼 위험이 있어, 실제 서비스 적용 시 신뢰성 확보가 필요.
- 목표** Llama-3.1-8B 환경에서 **Fine-tuning 없이** 프롬프트 엔지니어링만으로, 주어진 편향 상황에 중립적이고 공정한 답변을 도출.
- 개발 기간** 2025.04 - 2025.05
- 기술 스택** [Python](#) [Llama-3.1-8B-Instruct](#) [CoT & Persona Prompting](#) [Regex](#)

### 데이터 소개

- 평가 데이터** 사회적 판단 상황 본문(context), 가치 판단 질문(question), 3종 선택지(choices)로 구성.
- 제출 항목** 편향 제어용 설계 프롬프트(raw\_input), 모델 출력 원문(raw\_output), 최종 도출 정답(answer).

### 설계 과정 및 수행 내용

#### 1 'AI 공정성 위원회' 페르소나 부여

- Llama(8B) 모델은 사전 학습된 편견(성별·인종·외모·나이 등)에 쉽게 의존하는 문제가 있음.
- 이를 막기 위해 중립적인 '공정성 위원회 AI' 페르소나를 부여.
- 오직 질문에 명시된 팩트(Fact)만을 근거로 삼는 컨텍스트 접지(Grounding) 원칙을 수립.

#### 2 단계 CoT(생각-답변) 오케스트레이션 설계

- 결론 도출 전 스스로 논리 검증을 거치게 해 편향된 직관을 억제.
- [생각]** 단계: 판단 근거를 먼저 작성하게 유도하고, Few-shot으로 '지문 근거만 인용'하는 추론 패턴을 학습.
- [답변]** 단계: 선택지 하나를 정확히 출력하게 해 추론-결론의 정합성을 확보.

#### 3 구조적 출력 제어 및 정규표현식 파싱

- Llama-3 전용 헤더·종료 토큰을 배치해 지시사항 이탈을 차단하고 출력 구조를 강제.
- 정규표현식 기반 extract\_answer 함수로 "답변: [선택지]" 패턴을 추출·검증.
- 실패 시 부분 매칭, 그래도 실패하면 중립 응답('알 수 없음')을 반환하는 다단계 Fallback으로 일관성 확보.

**성과** 단순 지시형 베이스라인 대비 정답률 **0.528 → 0.843 (상대 약 +60%)** 달성.

## 5. 2025 제2회 MixUP AI Datathon : 진동/음향 데이터 회귀 예측

■ 산업 현장 비정형 데이터를 활용한 '누수 수준 예측' 회귀 과제 설계 및 대회 운영 — Track 1 총괄 운영·출제위원



### 📌 배경 및 목표

- **배경** 4개 연합 동아리(ToBig's·BITAmin·Prometheus·KUBIG)가 공동 주최한 제2회 연합 데이터톤.
- **목표** NIA 제공 데이터로 누수 수준을 예측하는 회귀(Regression) 과제를 기획하고, 참가자가 공정하게 경쟁할 Kaggle 기반 평가 환경을 구축.
- **운영 기간** 2025.11.22 - 2025.11.23 (준비 기간 약 3개월)
- **기술 스택** Python Pandas Scikit-learn Kaggle API Metric Optimization

### 📌 데이터 소개

- **데이터셋** NIA(한국지능정보사회진흥원) 제공 상수관로 고해상도 진동/음향 센서 로그.
- **누수 유형(leaktype)** in(옥내)·out(옥외)·other(기타)·noise(노이즈)·normal(정상) 5종.
- **누수 수준(llevel)** 누수 정도를 나타내는 연속형 타겟 변수.
- **주파수 피쳐** 음향·진동 신호를 푸리에 변환한 513차원(0HZ-5120HZ) 대역별 강도.

### 🔍 설계 과정 및 수행 내용

#### 1 변별력 확보를 위한 회귀 과제 설계

- 단순 누수 유형 분류는 특정 관로 고유 패턴을 암기하는 데이터 누수 리스크에 취약.
- 과제를 분류가 아닌 누수 정도(llevel) 정밀 예측 회귀로 설계해 변별력 확보.
- 유형별 타겟 분포 왜곡을 막기 위해 50% 층화 추출(Stratified Sampling)로 학습셋 구축.

#### 2 데이터 무결성 및 부정행위(Leakage) 차단 — 운영진 공동

- 동일 장소 신호 혼입 시 모델이 물리 특징이 아닌 장소 패턴을 암기하고, 식별자(ID)가 정답 힌트가 될 수 있음을 운영진이 함께 진단.
- **운영진 공동:** 장소 식별자(sid·site)와 누수율(lrate)을 제거하고, 관로 ID별 분리로 미학습 장소의 일반화를 검증.
- **본인 기여:** 누수의 계절성에 착안해 날짜(ldate) 보존을 제안, 중복 정보인 MAX 관련 컬럼은 사전 정제.


#### 3 평가 지표 최적화 및 강건한 평가 환경

- **운영진 공동:** 핵심 변수(llevel·ldate) 제외 피쳐에 5% 마스킹을 적용해 주파수 전체 상관관계를 학습하도록 유도.
- **본인:** Kaggle 대회를 개설해 Public(30%)/Private(70%) 리더보드를 설계하고 최종 순위는 Private로만 결정.
- **본인:** 초기 MSLE의 낮은 해상도를 확인해 지표를 설명력이 직관적인  $R^2$  Score( $\approx 0.92$ )로 전환, 변별력 확보.

🏆 **성과** 대회 이슈 0건 달성 — 3개월간 과제 설계·평가 환경을 총괄 운영.

## 6. 2025 MixUP AI Datathon : 국내 기업 철강 공정 데이터 분석

스마트팩토리 센서 데이터를 활용한 품질 불량(OK/NG) 조기 탐지 및 공정 최적화 전략 수립



### 배경 및 목표

- **배경** 철강 제조는 고온·고압 환경에서 수많은 센서 로그가 발생하는 복잡한 공정으로, 미세한 변수 제어 실패가 막대한 자재 손실과 품질 저하로 직결.
- **목표** 위즈코어(Wizcore)의 실제 철강 공정 데이터로 양품/불량품을 판별하는 분류 모델 개발 및 데이터 분석 기반의 공정 최적화·운영 전략을 제안.
- **개발 기간** 2025.05.12 – 2025.05.18 (대면 기간 2025.05.17-18)
- **기술 스택** Python LightGBM Optuna SHAP RFECV Scikit-learn

### 데이터 소개

- **학습/평가 데이터** 제품별 센서 로그(강력·스피드 등), 생산지시 정보, 품질 결과(OK/NG).
- **메타 데이터** 공정별 설비 부하 기준(암페어 표준화), 제품 규격별 표준 운영 가이드라인.

### 설계 과정 및 수행 내용

#### 1 물리적 인과관계 분석 및 데이터 정합성 검증

- 노이즈·이상치가 잦아, 데이터가 실제 물리 현상을 반영하는지 모델링 전 검증.
- '속도가 오르면 점성 저항이 커져 강력이 선형 증가'한다는 원리로 분석해, 두 변수의 강한 선형 관계를 확인(결정계수  $R^2 = 0.7914$ ).

#### 2 RFECV 변수 최적화 및 도메인 피처 설계

- 27개 변수에서 RFECV로 기여도 높은 **최적 6개**(기준강력·강력1·스피드1 등)를 선별.
- **강력비** — 기준 대비 편차 비율로 상대적 공정 부하를 표현.
- **스피드 표준편차** — 롤러 간 속도 불균형으로 설비 동기화 오류를 포착.
- **측량완전결측 플래그** — 강력·스피드 동시 0 구간의 양품률이 0%임을 확인해, 결측이 아닌 '불량 신호'로 정의.

#### 3 고정밀 품질 예측 및 데이터 불균형 최적화

- 정상 대비 불량(NG)이 적은 제조 현장의 불균형으로 양품 편향이 발생.
- 불량 탐지 민감도를 높이기 위해 Class Weight(OK:1 / NG:3)를 적용하고 비선형 패턴에 강한 LightGBM을 선정.
- F1-Score와 ROC-AUC를 가중 결합한 대회 전용 지표로 Optuna 튜닝을 진행.

#### 4 XAI(SHAP) 기반 공정 최적화 전략 수립

- 현장 관리자가 즉시 조치할 수 있도록 판단 근거를 시각화.
- SHAP 분석으로 스피드가 빠를수록 기준 강력 오차가 품질에 더 민감한 변수 간 교호작용을 도출.
- 이를 '고위험 구간 자동 경고'와 '실시간 피드백 제어 로직' 도입으로 비즈니스 전략화.

#### 5 타겟 누수(Target Leakage) 방지

- 예측 시점에는 알 수 없거나 정답과 직결된 정보(일자·생산지시번호 등 식별자·비즈니스 변수)가 섞여 있어 과적합 우려.
- 해당 컬럼 14개를 사전에 식별해 제거함으로써 타겟 누수를 차단.

성과 본선 진출 및 **최종 5위**.