



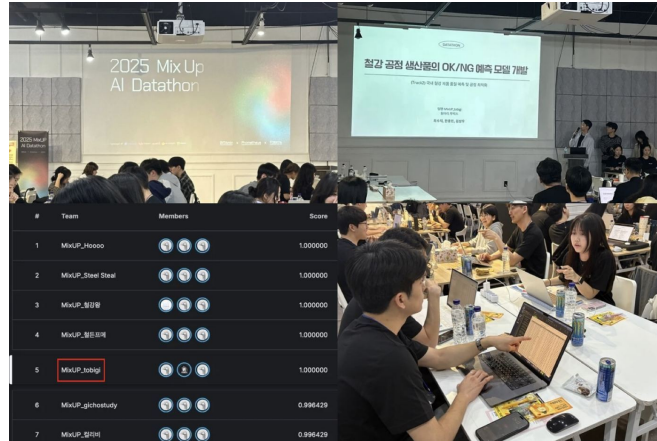
Sangwoo Kim

☎ (+82) 10-7378-4886 | ✉ swjohn0121@cau.ac.kr | 🏠 underove.github.io | 📺 Underove

“끊임없이 도전하고, 이론을 현실에서 작동하는 시스템으로 구현하는 과정을 즐깁니다.”

1. 2025 MixUP AI Datathon : 국내 기업 철강 공정 데이터 분석

스마트팩토리 센서 데이터를 활용한 품질 불량(OK/NG) 조기 탐지 및 공정 최적화 전략 수립



배경 및 목표

- **배경** 철강 제조는 고온·고압 환경에서 수많은 센서 로그가 발생하는 복잡한 공정으로, 미세한 변수 제어 실패가 막대한 자재 손실과 품질 저하로 직결.
- **목표** 위즈코어(Wizcore)의 실제 철강 공정 데이터로 양품/불량품을 판별하는 분류 모델 개발 및 데이터 분석 기반의 공정 최적화·운용 전략을 제안.
- **개발 기간** 2025.05.12 - 2025.05.18 (대면 기간 2025.05.17-18)
- **기술 스택** Python LightGBM Optuna SHAP RFECV Scikit-learn

데이터 소개

- **학습/평가 데이터** 제품별 센서 로그(강력·스피드 등), 생산지시 정보, 품질 결과(OK/NG).
- **메타 데이터** 공정별 설비 부하 기준(암페어 표준화), 제품 규격별 표준 운영 가이드라인.

설계 과정 및 수행 내용

1 물리적 인과관계 분석 및 데이터 정합성 검증

- 노이즈·이상치가 잦아, 데이터가 실제 물리 현상을 반영하는지 모델링 전 검증.
- '속도가 오르면 점성 저항이 커져 장력이 선형 증가'한다는 원리로 분석해, 두 변수의 높은 상관($R^2 = 0.7914$)을 확인.

2 RFECV 변수 최적화 및 도메인 피쳐 설계

- 27개 변수에서 RFECV로 기여도 높은 **최적 6개**(기준장력·장력1·스피드1 등)를 선별.
- **장력비** — 기준 대비 편차 비율로 상대적 공정 부하를 표현.
- **스피드 표준편차** — 롤러 간 속도 불균형으로 설비 동기화 오류를 포착.
- **측량완전결측 플래그** — 장력·스피드 동시 0 구간의 양품률이 0%임을 확인해, 결측이 아닌 '불량 신호'로 정의.

3 고정밀 품질 예측 및 데이터 불균형 최적화

- 정상 대비 불량(NG)이 적은 제조 현장의 불균형으로 양품 편향이 발생.
- 불량 탐지 민감도를 높이기 위해 Class Weight(OK:1 / NG:3)를 적용하고 비선형 패턴에 강한 LightGBM을 선정.
- F1-Score와 ROC-AUC를 가중 결합한 대회 전용 지표로 Optuna 튜닝을 진행.

4 XAI(SHAP) 기반 공정 최적화 전략 수립

- 현장 관리자가 즉시 조치할 수 있도록 판단 근거를 시각화.
- SHAP 분석으로 스피드가 빠를수록 기준 장력 오차가 품질에 더 민감한 변수 간 교호작용을 도출.
- 이를 '고위험 구간 자동 경고'와 '실시간 피드백 제어 로직' 도입으로 비즈니스 전략화.

5 타겟 누수(Target Leakage) 방지

- 예측 시점에는 알 수 없거나 정답과 직결된 정보(일자·생산지시번호 등 식별자·비즈니스 변수)가 섞여 있어 과적합 우려.
- 해당 컬럼 14개를 사전에 식별해 제거함으로써 타겟 누수를 차단.

🏆 **성과** 본선 진출 및 **최종 5위**.

2. LG Aimers 5기 : 디스플레이 공정 제품 이상탐지

디스플레이 조립 4개 공정의 공정 변수로 제품 양품/불량을 판별하는 이진 분류 — 클래스 불균형 완화와 AutoML 앙상블

배경 및 목표

- **배경** 디스플레이 패널 조립은 여러 단계 공정을 거치며 다수의 센서·판정 로그가 쌓이는데, 불량은 드물게 발생해 정상 데이터에 묻히기 쉬움 — 희소한 불량을 놓치지 않는 탐지가 품질 관리의 핵심.
- **목표** 4개 조립 공정(Dam·Fill1·Fill2·AutoClave)의 공정 변수로 최종 제품의 양품(Normal)/불량(AbNormal)을 예측하는 이진 분류 모델을 개발.
- **개발 기간** 2024.07 – 2024.08 (LG Aimers 5기 온라인 해커톤, 개인)
- **기술 스택** Python Pandas Scikit-learn PyCaret LightGBM XGBoost Extra Trees
- **평가 지표** F1 Score (불균형 이진 분류 — 정확도가 아닌 F1로 평가)

데이터 소개

- **학습/평가 데이터** 디스플레이 조립 4개 공정(Dam·Fill1·Fill2·AutoClave)의 공정 변수 — 설비·라인·모델 식별자, 압력·챔버 온도 판정값, 검사 판정 코드, 헤드 좌표 등. 타깃 = Normal / AbNormal.
- **데이터 특성** 범주형·수치형이 혼재하고 결측이 많으며, 불량(AbNormal)이 희소한 클래스 불균형 — 전처리·불균형 처리가 성능을 좌우.

설계 과정 및 수행 내용

1 결측·이상값 정제

- 결측 비율이 50% 이상인 열은 신호 대비 잡음이 커 train·test 모두에서 제거.
- 수치형이어야 할 헤드 좌표 3개 열에 판정 문자열 'OK'가 섞여 있어, 이를 결측으로 통일한 뒤 train 중앙값으로 대체(동일 값을 test에 적용해 누수 차단).

2 범주형 인코딩 및 학습/평가 열 정합

- 설비(Equipment)·라인(Wip Line)·모델(Model.Suffix)·공정 설명·검사 판정 등 범주형 27개 열을 One-Hot 인코딩.
- train·test의 열 집합·순서를 정렬(align)하고 한쪽에만 있는 범주 열은 0으로 채워, 두 데이터의 피쳐 공간을 일치.
- 타깃(Normal/AbNormal)만 Label Encoding으로 수치화.

3 클래스 불균형 완화

- 불량이 희소해 다수 클래스(Normal)를 불량 대비 **5:1**로 언더샘플링, 학습이 정상 쪽으로 편향되는 것을 완화.
- 남은 불균형은 학습 파이프라인의 불균형 보정(fix_imbalance) 단계에서 추가로 처리.

4 PyCaret AutoML 모델 탐색 및 Soft-Voting 앙상블

- 대회 기간이 짧아 PyCaret으로 여러 분류 모델을 F1 기준 10-Fold 교차검증으로 일괄 비교, 상위 3개를 선별.
- 선정된 **LightGBM**·**XGBoost**·**Extra Trees**를 각각 학습한 뒤, 세 모델의 예측 확률을 평균하는 Soft-Voting으로 블렌딩해 단일 모델의 분산을 완화.

5 검증 전략

- 언더샘플링한 학습 데이터를 클래스 비율 유지(stratify)로 8:2 분할, 20% 홀드아웃 검증셋으로 일반화 성능을 점검.
- 모델 선정 단계에서도 10-Fold 교차검증 F1을 기준으로 삼아 특정 분할 편향을 줄임.

3. 2026 DAICON : 스마트 창고 출고 지연 예측 AI 경진대회

AMR(자율이동로봇) 스마트 물류창고 운영 데이터를 기반으로, 출고 지연 시간을 미리 예측하는 모델 개발



배경 및 목표

- 배경 로봇으로 운영되는 스마트 창고의 출고 지연은 로봇·주문량·혼잡도 등 다수 요인이 얹혀 발생. 사전 예측으로 선제 조치 가능한 모델이 필요.
- 목표 12,000개의 독립적인 창고 운영 시나리오를 학습해 **향후 30분간의 평균 출고 지연 시간(분)**을 예측 (평가 지표: MAE).
- 개발 기간 2026.04.01 – 2026.05.04
- 기술 스택 Python PyTorch LightGBM CatBoost XGBoost Bi-GRU MultiheadAttention Optuna SciPy(SLSQP) Dash

데이터 소개

- 시나리오 12,000개 × 25 timestep 운영 로그 + 창고 300개 정적 메타정보(통로 폭·교차로 수·포장대 등).
- 분포 특성 Train 250 / Test 100 / 교집합 50 / Test에만 50. 학습에 없던 신규 창고 일반화가 핵심.

설계 과정 및 수행 내용

1 시계열 구조 복원 + AMR 도메인 피쳐 설계

- 행 순서가 뒤섞여 있어, 시나리오 ID·행 번호로 재정렬해 시간 순서를 복원하고 시점 인덱스(0-24)를 피쳐화.
- 핵심 지표 8개에 시간 변형 4종(lag·rolling·pure-past·시나리오 평균)을 적용.
- AMR 도메인 합성 피쳐(교차로 지연 비용, 단계별 부하 지표(포장 병목·충전기 압력 등), 실질 혼잡도 = 혼잡도 × 교차로 밀도 / 통로 폭)로 '좁은 통로일수록 같은 혼잡도가 더 큰 지연'을 수식화.

2 신규 창고 일반화: kNN 인코딩 + GroupKfold

- kNN 인코딩 — 창고 정적 정보 13개와 구조 타입을 정규화해, 코사인 거리로 유사한 5개 창고의 평균·표준편차·최댓값을 피쳐화(자기 자신 제외로 유출 차단).
- GroupKfold(by layout_id) — 같은 창고가 학습·검증에 동시 등장하지 않게 분할해 신규 창고만으로 검증.

3 다중 모델 앙상블 + SLSQP 가중치 최적화

- 트리 모델만으로는 25개 시간 구간의 흐름을 학습하기 어려워 트리 3종과 시퀀스 2종을 함께 구성(XGBoost는 뒤 진단에서 노이즈로 판명되어 제외, 최종 4모델).
- 트리 3종(LightGBM·CatBoost·XGBoost)은 Optuna로 GroupKFold 탐색, 비대칭 분포 보정을 위해 log1p 학습 + expm1 복원.
- Bi-GRU는 (25, N) 시퀀스로 재구성해 LSTM 대비 파라미터를 절감, 신규 창고 일반화에 유리(LB 10.1669 → 10.0194 수직 상승).
- Bi-GRU + Multi-Head Attention은 4-head·잔차 연결·LayerNorm으로 먼 시점 관계를 포착.
- SLSQP로 OOF 최소화 가중치를 자동 탐색(합=1).

4 OOF-LB 디커플링 진단 및 모델 재구성

- OOF-LB 갭 1.4가 지속되고 'OOF 개선 / LB 악화'가 4~5회 반복 — 검증 지표 자체의 구조적 문제로 판단.
- (1) train/test 분류기가 AUC = 1.0으로 완전 분리됨을 확인. 타깃 예측 순위와 adversarial 순위의 차로 누수 점수를 정량화해 피쳐 5개 제거(트리만 재학습, GRU/Attention은 시퀀스 신호 보존) → LB 9.9983 → 9.9917.
- (2) SLSQP에서 XGBoost 가중치가 0.0100으로 수렴 — 노이즈로 판단·제외, 4모델로 재구성(가중치 재분배: LightGBM 0.20 → 0.28, CatBoost 0.16 → 0.17, GRU 0.29, Attention GRU 0.26) → LB 9.9917 → 9.9890.


5 Dash 기반 운영 대시보드 구현

- '예측 → 진단 → 시뮬레이션 → 액션'을 한 화면에 잇는 6개 섹션(물류 파이프라인 → 현재 예측 → 시점별 추이·알림 → SHAP 기여 분해 → 운영 패턴 Radar → What-If)을 설계.
- What-If 슬라이더로 핵심 신호 4개를 조정하면 연동된 16개 합성 피쳐가 자동 재계산되어 즉시 새 예측을 표시.
- 학습 노트북의 피쳐 엔지니어링을 모듈화하고, 50,000행 캐시 + 20개 모델(5-fold × 4종) + SHAP 사전 계산(50,000 × 168)으로 원인 신호까지 즉시 제공.

 **성과** 베이스라인 MAE **12.6160** → **9.9890** 개선, **최종 68위 (상위 11%)**.

4. LG Aimers 7기 : 식음업장 메뉴 수요 예측 AI 모델 (Phase 3)

시계열 데이터 분석을 통한 식음업장 1주일 단위 메뉴별 판매량 예측



배경 및 목표

- 배경** 리조트 식음업장은 투숙객 수뿐 아니라 날씨·주변 관광 시설(스키장·화담숲) 이용객 등 다양한 요인으로 수요가 크게 변동. 운영 효율화·재고 관리를 위한 데이터 기반 수요 예측이 필수.
- 목표** 리조트 메뉴별 판매 데이터(최대 28일치)로 향후 1주일간 각 메뉴의 예상 판매량을 예측하는 AI 모델을 개발.
- 개발 기간** 2025.08 – 2025.09 (Phase 3: 2025.09.06–07)
- 기술 스택** Python Pandas CNN BiLSTM Scikit-learn SMAPE

데이터 소개

- 매출 데이터** 8개 영업장 내 167개 메뉴별 매출 수량(2023–2024).
- 리조트 메타** 18종 객실 타입별 판매 실적, 업장별 단체 예약 건수, 주변 시설(화담숲·스키장) 방문객 수.
- 외부 환경** 지역 기온·강수량 등 기상 정보 연동.

설계 과정 및 수행 내용

1 데이터 무결성 확보를 위한 전처리

- 과대값(Outlier)과 단체 주문 스파이크(Spike)가 모델 학습을 왜곡.
- 99% 분위수 Winsorizing으로 이상치를 보정하고, 단체 메뉴의 0값을 메뉴별 중앙값으로 대체해 학습 안정성 확보.

2 도메인 특화 피쳐 엔지니어링

- 시계열 피쳐** — 요일/월 주기성(sin/cos), 7일 이동평균(ma7).
- 현장 운영 플래그** — 화담숲·스키장 폐장기, 단풍/스키 시즌 등 운영 기간별 노이즈 제어.
- 소비 패턴** — 징검다리 연휴, 신규/대체 메뉴 출시로 인한 기존 메뉴 자기잠식 효과 반영.
- 신규 메뉴 대응** — 각 메뉴 첫 판매 시점 기준 판매 가능 여부·출시 경과일 피쳐 생성.

3 1D CNN + BiLSTM 하이브리드 아키텍처

- 요일별 반복 '단기 패턴'과 특수 시즌 '장기 맥락'이 공존 — 둘을 동시에 포착하는 구조 필요.
- 식당·메뉴 정보를 정적 임베딩으로 벡터화 후 시간축 결합, 단일 모델로 모든 메뉴 예측.
- 1D CNN으로 단기 변동을, BiLSTM으로 양방향 시계열 맥락을 파악.

4 커스텀 복합 손실 함수 + 2단계 학습

- MSE는 판매량이 큰 메뉴 오차에 편향돼 소량 메뉴 예측력이 저하.
- MSE로 기본 패턴을 Warm-up한 뒤 SMAPE/NMAE/NRMSE 결합 '복합 손실'로 파인튜닝 — 성능 약 22% 개선.


5 24-Fold 롤링 교차 검증 및 후처리

- 특정 시점 편향·과적합을 줄이고 시간적 강건성을 확보하기 위해 7일 슬라이딩 24-Fold Rolling CV + 앙상블로 일반화.
- 실수 출력값을 판매 수량 특성에 맞춰 정수형으로 반올림하는 후처리 적용.

성과 Phase 3 본선 진출, 전국 800여 팀 중 최종 5위.

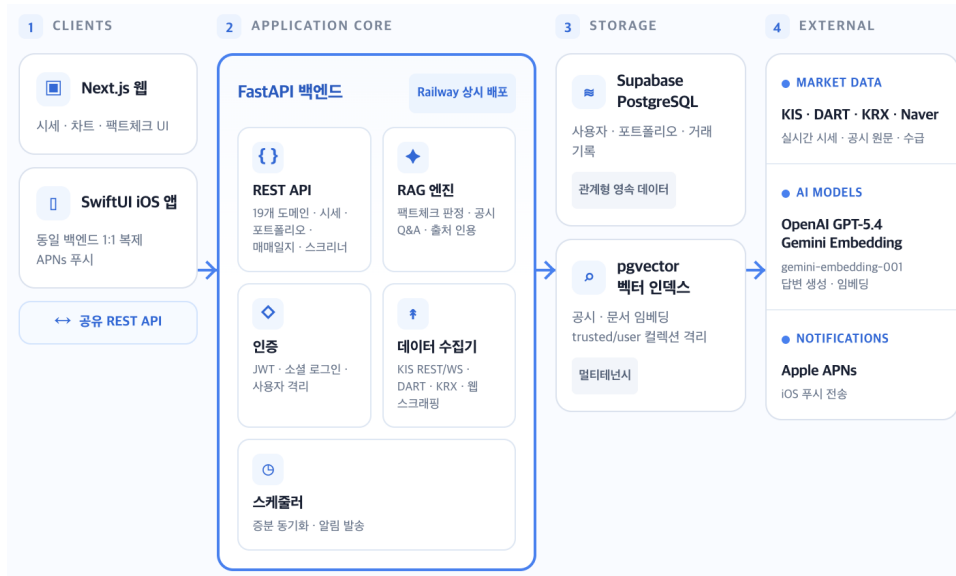
5. Personal Project : N.O.V.A — AI 주식 정보 팩트체크 서비스 (웹·iOS)

KIS 실시간 시세와 DART 공시 RAG를 결합해 리포트·지라시를 교차검증하는 폴스택 주식 서비스 — 백엔드·웹·iOS 개발과 클라우드 배포·운영까지



■ 배경 및 목표

- **배경** 출처 불명의 리포트·지라시가 메신저로 유통되지만, 개인 투자자가 이를 공식 자료와 대조해 검증할 수단이 마땅치 않음.
- **목표** 공식 공시(DART)·실시간 시세와 교차검증하는 팩트체크를 중심으로, 시세·차트·포트폴리오 관리까지 갖춘 서비스를 웹·iOS로 개발하고 클라우드에 배포.
- **개발 기간** 2026.05 – 2026.06 (1인 폴스택, AI 코딩 도구 활용)
- **기술 스택** [FastAPI](#) [Next.js](#) [SwiftUI](#) [pgvector](#) [Supabase](#) [GPT-5.4](#) [Gemini Embedding](#) [KIS API](#) [Railway](#) [APNs](#)
- **배포·규모** Railway 상시 운영 (백엔드·웹) / iOS 실기기 (APNs 검증) / REST API 19개 도메인 · 외부 수집기 5종



설계 과정 및 수행 내용

1 DART 공시 기반 RAG 팩트체크 파이프라인

- LLM 단독 판정은 근거 없는 확인(할루시네이션) 위험이 있음 — 판정의 근거를 공식 자료에서 검색해 출처와 함께 제시하는 구조가 필요.
- 인덱싱** — DART 공시 본문(800자·오버랩 150자)과 사용자 업로드 PDF를 청킹하고, Gemini 임베딩(gemini-embedding-001, 3072차원)으로 벡터화해 PostgreSQL(pgvector)에 저장.
- 컬렉션 분리** — 공용 신뢰 자료(trusted)와 사용자 문서(user_uploads)를 별도 컬렉션으로 격리하고 사용자명 필터를 강제해, 남의 문서가 검색되지 않는 멀티테넌시를 구현.
- 검색·생성** — 질문마다 두 컬렉션에서 top-5 유사도 검색 후 “[자료 N — 출처]” 형식의 컨텍스트를 구성, GPT-5.4가 출처를 인용한 답변을 생성 — 팩트체크 결과는 신뢰도 신호등으로 표시.

2 팩트체크 응답 지연 개선 (142초 → 약 8초)

- 요청마다 대상 기업의 공시 전체를 다시 수집·인덱싱하는 구조여서 첫 응답까지 142초가 소요 — 서비스로 쓸 수 없는 수준.
- 증분 동기화** — 이미 인덱싱된 공시는 건너뛰도록 동기화 로직을 재설계하고, 신규 수집을 병렬화해 응답 시간을 약 8초로 단축.

3 실시간 시세 파이프라인과 iOS 확장


- KIS API 연동** — REST(분봉·일봉 차트)와 WebSocket(실시간 체결가) 이중 채널로 시세를 수집. 토큰 발급이 하루 1회로 제한되는 정책에 맞춰 토큰 캐싱·재사용 구조를 설계.
- 수급 데이터 보완** — 외국인·기관 순매수는 API가 제공하지 않아 Naver 금융 스크래핑으로 대체 수집.
- iOS 앱** — 동일 백엔드를 공유하는 SwiftUI 네이티브 앱으로 웹을 1:1 복제, 모바일 소셜 로그인 엔드포인트를 추가하고 APNs 푸시를 실기기로 검증.

4 멀티유저 보안 — 독립 리뷰 프로세스

- 1인 개발은 자신이 만든 코드의 보안 구멍을 스스로 발견하기 어려움 — 별도 AI 리뷰어를 두고 적대적 코드 리뷰를 프로세스로 고정.
- 발견·수정** — 다른 사용자의 데이터에 접근 가능한 수평 권한 문제, APNs 디바이스 토큰이 이전 사용자에게 남는 누수 등 멀티유저 이슈를 발견하고 수정 — 인증·데이터 접근 경로에 사용자 격리를 일괄 적용.

6. ToBig's 20th Conference : Pi-FiRi — 엣지 디바이스 기반 실시간 화재 감지 로봇


라즈베리파이 로봇과 LLM Agent를 결합한 실시간 자율 순찰 및 화재 대응 시스템



배경 및 목표

- **배경** 지하주차장·물류창고 등 사각지대가 많은 실내는 고정형 센서만으로 신속한 대응이 어려우며, 화재 위치나 규모를 사람이 직접 판단해야 하는 위험이 존재.
- **목표** 상용 로봇 키트에 정밀 제어·환경 센서를 통합하고, LLM Agent로 화재를 실시간 탐지·분석·보고하는 '지능형 화재 감지 시스템'을 개발.
- **개발 기간** 2025.05 - 2025.07
- **기술 스택** Python TensorFlow Raspberry Pi EfficientDet-Lite1 Flask LangChain Solar Pro2 OpenCV PID Control Streamlit

파이프라인



시스템 및 하드웨어 구성

- **EfficientDet-Lite1** 엣지 구동을 위해 TFLite 모델 중 속도(49ms)와 정확도(mAP 30.55%)의 균형점인 'Lite1'을 선정하고, Roboflow Universe의 Fire&Smoke Dataset을 수집·증강해 파인튜닝.
- **연속 감지 필터링** 단일 프레임 노이즈로 인한 오탐을 막기 위해, 0.5 임계값 이상 탐지가 1.2초 연속 유지될 때만 화재로 확정.
- **Pi-Camera** 화재·연기를 탐지하고 실시간 영상 스트리밍을 서버로 전송하는 로봇의 '눈' 역할.
- **GrayScale Sensor** 바닥 라인을 실시간 인식해 지정 경로를 따라가는 라인 트레이싱으로 정해진 구역을 상시 순찰.
- **DHT11 Sensor** 카메라 영상만으로는 알 수 없는 현장 온·습도를 관제 대시보드와 실시간 Q&A에서 함께 확인.
- **ArUco Marker (OpenCV)** 로봇의 현재 위치와 화재 발생 지점을 파악하기 위해 경로 구간별로 도입.

1 PID 제어 로직을 통한 주행 안정화 (하드웨어 한계 보완)

- PiCar-4WD 키트를 단순 if-else 조건문으로 제어하면, 모터 출력 불균형 때문에 주행이 좌·우로 흔들리는 현상(Hunting) 현상과 경로 이탈이 발생 — 상용 키트의 하드웨어 한계를 제어 로직으로 보완해야 함.
- GrayScale 센서가 읽은 바닥 라인의 오차(e)를 수치화하고, **PID 제어**로 좌·우 모터 출력을 실시간 미세 조정해 이탈 없는 라인 트레이싱 환경을 구축.
 - **I(적분) 제어** — 누적 오차를 반영해, 모터 출력 저하로 한쪽으로 쏠리는 주행 편향을 보정.
 - **D(미분) 제어** — 오차의 변화율을 감지해, 조향 시 발생하는 떨림을 억제하고 부드러운 주행을 구현.

2 분산 컴퓨팅 아키텍처 설계 (엣지 연산 한계 극복)

- 엣지 환경(라즈베리파이)에서 주행 제어와 고부하 AI 추론을 동시에 수행하면 연산 지연으로 **1 FPS**까지 떨어져, 실시간 구동 자체가 불가능.
- 라즈베리파이와 로컬 PC를 동일한 모바일 핫스팟(WLAN)에 연결해 하나의 서브넷을 구성하고, 역할을 분리.
 - **라즈베리파이** — Flask API 서버를 올려 카메라 영상과 센서 데이터를 스트리밍하는 역할만 담당.
 - **로컬 PC** — 전송받은 프레임에 EfficientDet-Lite1 추론을 수행하고 결과를 회신.
- 이 분산 구조로 처리량을 약 **10 FPS**까지 끌어올려, 주행과 탐지가 동시에 도는 실시간성을 확보.

3 Agentic AI 리포팅 (Solar Pro2)

- 기존 경보 시스템은 경고음만 울릴 뿐, 화재의 발생 위치나 규모는 사람이 직접 판단해야 함 — 탐지 결과를 사람이 읽을 수 있는 상황 보고로 바꿀 필요.
- 로봇이 탐지한 화재 메타데이터(감지 시간·객체 크기·예측 확률·위치)를 LangChain PromptTemplate으로 동적 주입해, Solar Pro2 기반 분석 결과를 생성.
 - **4단계 위험도 경고** — 예측 확률과 객체 크기를 종합해 [관심-주의-경계-심각]으로 분류한 자연어 메시지를 생성.
 - **순찰 보고서 생성** — 순찰 시작·종료 시간, 구간별 통과 로그, 화재 이벤트를 사실에 근거해 작성. temperature=0과 다중 제약 시스템 프롬프트로 환각을 차단하고, 같은 입력에 같은 결과를 내는 재현성을 확보해 일관된 평가가 가능한 응답 체계를 구축.
 - **실시간 Q&A** — “현재 로봇의 위치는 어디야?”와 같은 질문에, 수집된 순찰 데이터를 근거로 실시간 답변.

4 Streamlit 관제 대시보드 구축

- 실시간 영상 스트리밍, 온·습도 센서 수치, PID 파라미터 제어, 로봇 주행 상태, LLM Agent 응답을 하나의 인터페이스에 통합 시각화.
- 관제자가 화면 전환 없이 “탐지 → 판단 → 조치”를 한 곳에서 수행하도록 해 관제 효율을 극대화.